

ГЕНЕРАТИВНЫЙ ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

Структура и содержание дисциплины в логике компетентностно-ролевой модели

Курс: 3-й курс, 5-й семестр | **Трудоёмкость:** 5 ЗЕ (180 часов) | **Аттестация:** экзамен

Компетенции КРМ:

ML-2 ML-3 PL-1 DL-2 LLM-5 FC-2 SS-1

Роли (КРМ 3.0):

ML Engineer AI Engineer AI Architect

ПРЕРЕКВИЗИТЫ

Дисциплины, необходимые для освоения курса

Обязательные дисциплины

Дисциплина	Необходимые знания и навыки	Уровень
Алгоритмизация и программирование	Python, NumPy, Pandas, базовые алгоритмы	Базовый
Дискретная математика	Теория графов, комбинаторика, теория вероятностей	Базовый
Высшая математика	Матан, линейная алгебра, оптимизация, статистика	Базовый
Основы машинного обучения	Обучение с учителем/без учителя, метрики, градиентный спуск	Базовый

СТРУКТУРА ДИСЦИПЛИНЫ

Модуль	Содержание	Часы	Компетенции
М1	Введение в генеративный ИИ + основы работы с данными в Python	10 ч	ML-2, PL-1
М2	Автоэнкодеры и вариационные автоэнкодеры (VAE)	18 ч	ML-3, FC-2
М3	Генеративно-сопоставительные сети (GAN)	6 ч	ML-3
М4	Трансформеры и большие языковые модели (LLM)	28 ч	LLM-5, FC-2
М5	RAG-системы и мультимодальный ИИ	18 ч	LLM-5, FC-2, PL-1, SS-1
М6	AI-агенты, развёртывание и диффузионные модели	26 ч	ML-3, LLM-5, PL-1
ИТОГО (контактная работа)		106 ч	5 3Е (180 ч)

Форма промежуточной аттестации: экзамен

Уровни освоения: Базовый (Б), Базовый/Средний (Б/С)

МОДУЛЬ 1

Введение в генеративный ИИ + основы работы с данными в Python

10 часов

ML-2, PL-1

Базовый

Содержание:

- Краткая история ИИ, типы машинного обучения (с учителем, без учителя, с подкреплением)
- Понятие генеративного ИИ, дискриминативные vs генеративные модели
- Обзор современных применений: ChatGPT, Midjourney, GitHub Copilot
- Основы работы с данными в Python (NumPy, Pandas)
- Предварительный анализ данных и визуализация (EDA, matplotlib, seaborn)

Практика: Google Colab, загрузка датасетов, базовые операции, автоматизация обработки данных, интерактивные дашборды (Plotly/Dash)

МОДУЛЬ 2

Автоэнкодеры и вариационные автоэнкодеры (VAE)

18 часов

ML-3, FC-2

Б/С

Содержание:

- Архитектура автоэнкодера (encoder + bottleneck + decoder)
- Латентное пространство и ошибка реконструкции
- Вариационные автоэнкодеры (VAE): параметризация распределения, репараметризационный трюк
- Функция потерь VAE (reconstruction + KL-дивергенция)
- Генерация новых данных из латентного пространства

Практика: Построение автоэнкодера на Fashion-MNIST, генерация из латентного пространства VAE

МОДУЛЬ 3

Генеративно-сопоставительные сети (GAN)

6 часов

ML-3

Б/С

Содержание:

- Архитектура GAN (генератор + дискриминатор)
- Минимаксная игра, функция потерь GAN
- Проблемы обучения: затухающие градиенты (vanishing gradients), коллапс мод (mode collapse)
- DCGAN и улучшения (label smoothing, спектральная нормализация)

Практика: Запуск предобученной DCGAN, генерация изображений, обучение DCGAN с нуля, расчёт FID/KID метрик

МОДУЛЬ 4

Трансформеры и большие языковые модели (LLM)

28 часов

LLM-5, FC-2

Б/С

Содержание:

- Ограничения RNN, механизм внимания (Attention)
- Self-Attention и архитектура Трансформер (Transformer)
- Авторегрессионная генерация (GPT)
- Инженерия промптов (Prompt Engineering): Zero-Shot, Few-Shot, Chain-of-Thought
- Архитектуры современных больших языковых моделей (LLM): Llama, Mistral, Qwen
- PEFT методы: LoRA, QLoRA, Prefix Tuning
- 4-битная квантование (bitsandbytes)

Практика: Hugging Face Transformers (BERT, GPT-2), Fine-tuning BERT, LoRA/QLoRA дообучение с peft, работа с API LLM

МОДУЛЬ 5

RAG-системы и мультимодальный ИИ

18 часов

LLM-5, FC-2, PL-1, SS-1

Б/С

Содержание:

- RAG (Retrieval-Augmented Generation): архитектура и преимущества
- Векторные базы данных: Chroma, FAISS, Pinecone, Weaviate
- Эмбединги и гибридный поиск
- Оценка качества RAG (RAGAS метрики)
- Мультимодальные модели (CLIP, LLaVA, GPT-4V)
- Visual Question Answering (ответ на вопросы по изображениям)
- Этические риски: deepfakes, bias, авторское право

Практика: Построение RAG-системы с LangChain, гибридный поиск, reranking, мультимодальные прототипы, этический аудит

МОДУЛЬ 6

AI-агенты, развёртывание и диффузионные модели

26 часов

ML-3, LLM-5, PL-1

Б/С

Содержание:

- AI-агенты: концепция, отличие от чат-ботов
- Архитектура ReAct (Reason + Act)
- Типы инструментов (tools), function calling
- Мульти-агентные системы (LangGraph, AutoGen, CrewAI)
- Диффузионные модели (Stable Diffusion)
- Квантование моделей (INT8, INT4, GGUF)
- Оптимизация инференса: пакетная обработка (batching), кэширование (caching)
- Платформы: vLLM, TGI, Hugging Face Spaces

Практика: AI-агент с LangChain, мульти-агентная система, пайплайн Stable Diffusion, DreamBooth fine-tuning, FastAPI + Docker, кэширование (Redis)

ПРОМЕЖУТОЧНАЯ АТТЕСТАЦИЯ

Экзамен

- Форма:** устный экзамен (2 теоретических вопроса)
- Охват:** все модули дисциплины
- Проверяемые компетенции:** ML-2, ML-3, PL-1, LLM-5, FC-2, SS-1

Критерии оценки:

Баллы	Критерий
35-40	Полный самостоятельный верный ответ, концептуальное понимание, примеры
29-34	Достаточно полный ответ, небольшие неточности
22-28	Неполный ответ, трудности при обобщении
0-21	Разрозненные знания, ошибки в определениях

ПРАКТИЧЕСКИЕ НАВЫКИ

ML Engineer

- Реализация MLP, автоэнкодеров, GAN с нуля
- Сравнение архитектур и оптимизаторов
- Расчёт метрик качества (FID, MSE, F1-score)

AI Engineer

- LoRA/QLoRA дообучение LLM
- Построение RAG-систем с LangChain
- Развёртывание моделей (FastAPI, Docker)

Prompt Engineer

- Zero-Shot, Few-Shot, Chain-of-Thought промпты
- Управление параметрами генерации (temperature, top_p)
- Итеративная отладка и оптимизация промптов

AI Architect

- Проектирование RAG-систем
- Архитектура AI-агентов
- Выбор моделей и оптимизация

ТЕХНОЛОГИЧЕСКИЙ СТЕК

Языки и библиотеки

- **Python** — основной язык
- **NumPy, Pandas** — работа с данными
- **PyTorch, Keras** — фреймворки глубокого обучения
- **Hugging Face Transformers** — большие языковые модели (LLM) и токенизаторы
- **LangChain** — RAG-системы и AI-агенты
- **diffusers** — диффузионные модели
- **FastAPI, Docker** — развёртывание

Платформы и сервисы

- **Google Colab** — обучение и эксперименты
- **Hugging Face Hub** — модели и датасеты
- **vLLM, TGI** — инференс (выполнение) больших языковых моделей (LLM)
- **Chroma, FAISS** — векторные БД
- **Weights & Biases** — эксперименты
- **MLflow** — управление моделями

ЛИТЕРАТУРА И РЕСУРСЫ

Основная литература:

1. Goodfellow I. et al. "Generative Adversarial Nets" (2014)
2. Kingma D.P. "Auto-Encoding Variational Bayes" (2014)
3. Vaswani A. et al. "Attention Is All You Need" (2017)
4. Ho J. et al. "Denoising Diffusion Probabilistic Models" (2020)
5. Brown T. et al. "Language Models are Few-Shot Learners" (2020)
6. Rombach R. et al. "Stable Diffusion" (2022)
7. Hu E.J. et al. "LoRA" (2022)
8. Touvron H. et al. "Llama 2" (2023)
9. Lewis P. et al. "RAG" (2020)
10. Yao S. et al. "ReAct" (2023)

Онлайн-курсы:

- **Hugging Face Course** — <https://huggingface.co/learn>
- **DeepLearning.AI Short Courses** — <https://www.deeplearning.ai/short-courses/>
- **LangChain Documentation** — <https://docs.langchain.com/>

Журналы:

- Journal of Machine Learning Research (JMLR)
- Transactions of the Association for Computational Linguistics (TACL)

- Journal of Artificial Intelligence Research (JAIR)
- Machine Learning (Springer)
- Neural Networks (Elsevier)
- Nature Machine Intelligence
- arXiv.org (cs.LG, cs.CL, cs.CV)

ФОНД ОЦЕНОЧНЫХ СРЕДСТВ

Модули и формы контроля

Модуль	Компетенции	Форма контроля	Баллы
М1 Введение + Python	ML-2, PL-1	Практика, отчёты	до 25
М2 Автоэнкодеры и VAE	ML-3, FC-2	Практика, отчёты	до 35
М3 GAN	ML-3	Практика, отчёты	до 30
М4 Трансформеры и LLM	LLM-5, FC-2	Практика, отчёты	до 40
М5 RAG и мультимодальный ИИ	LLM-5, FC-2, PL-1, SS-1	Практика, этический отчёт	до 40
М6 AI-агенты и развёртывание	ML-3, LLM-5, PL-1	Практика, отчёты	до 30
Контрольная	Все модули	Тестирование	до 40
ИТОГО			до 240

Промежуточная аттестация:

Экзамен (2 теоретических вопроса) — до 40 баллов

Максимум за курс: 280 баллов

ИТОГИ ОБУЧЕНИЯ

После завершения дисциплины студент сможет:

-  Работать с современными большими языковыми моделями (LLM: Llama, Mistral, Qwen)
-  Применять методы эффективного дообучения (PEFT: LoRA, QLoRA)
-  Строить RAG-системы (Retrieval-Augmented Generation) с векторными базами данных
-  Разрабатывать AI-агентов с использованием инструментов
-  Развёртывать генеративные модели в production (промышленной эксплуатации)
-  Оценивать качество генеративных моделей
-  Анализировать этические риски и bias (смещения) в ИИ-системах

РАБОЧАЯ ПРОГРАММА ДИСЦИПЛИНЫ

Генеративный искусственный интеллект

2026