

ГЕНЕРАТИВНЫЙ ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

Структура и содержание дисциплины в логике компетентностно-ролевой модели

Курс: 3-й курс, 5-й семестр | **Трудоёмкость:** 5 ЗЕ (180 часов) | **Аттестация:** экзамен

Компетенции КРМ:

ML-2 ML-3 PL-1 DL-2 LLM-5 FC-2 SS-1

Роли (КРМ 3.0):

ML Engineer AI Engineer AI Architect

ПРЕРЕКВИЗИТЫ

Дисциплины, необходимые для освоения курса

Обязательные дисциплины

Дисциплина	Необходимые знания и навыки	Уровень
Алгоритмизация и программирование	Python, NumPy, Pandas, базовые алгоритмы	Базовый
Дискретная математика	Теория графов, комбинаторика, теория вероятностей	Базовый
Высшая математика	Матан, линейная алгебра, оптимизация, статистика	Базовый
Основы машинного обучения	Обучение с учителем/без учителя, метрики, градиентный спуск	Базовый

СТРУКТУРА ДИСЦИПЛИНЫ

Модуль	Содержание	Часы	Компетенции
М1	Введение в генеративный ИИ + основы работы с данными в Python	10 ч	ML-2, PL-1
М2	Автоэнкодеры и вариационные автоэнкодеры (VAE)	18 ч	ML-3, FC-2
М3	Генеративно-сопоставительные сети (GAN)	6 ч	ML-3
М4	Трансформеры и большие языковые модели (LLM)	28 ч	LLM-5, FC-2
М5	RAG-системы и мультимодальный ИИ	18 ч	LLM-5, FC-2, PL-1, SS-1
М6	AI Agents, развёртывание и диффузионные модели	26 ч	ML-3, LLM-5, PL-1
ИТОГО (контактная работа)		106 ч	5 3E (180 ч)

Форма промежуточной аттестации: экзамен

Уровни освоения: Базовый (Б), Базовый/Средний (Б/С)

МОДУЛЬ 1

Введение в генеративный ИИ + основы работы с данными в Python

10 часов

ML-2, PL-1

Базовый

Содержание:

- Краткая история ИИ, типы машинного обучения (с учителем, без учителя, с подкреплением)
- Понятие генеративного ИИ, дискриминативные vs генеративные модели
- Обзор современных применений: ChatGPT, Midjourney, GitHub Copilot
- Основы работы с данными в Python (NumPy, Pandas)
- Предварительный анализ данных и визуализация (EDA, matplotlib, seaborn)

Практика: Google Colab, загрузка датасетов, базовые операции, автоматизация обработки данных, интерактивные дашборды (Plotly/Dash)

МОДУЛЬ 2

Автоэнкодеры и вариационные автоэнкодеры (VAE)

18 часов

ML-3, FC-2

Б/С

Содержание:

- Архитектура автоэнкодера (encoder + bottleneck + decoder)
- Латентное пространство и ошибка реконструкции
- Вариационные автоэнкодеры (VAE): параметризация распределения, репараметризационный трюк
- Функция потерь VAE (reconstruction + KL-дивергенция)
- Генерация новых данных из латентного пространства

Практика: Построение автоэнкодера на Fashion-MNIST, генерация из латентного пространства VAE

МОДУЛЬ 3

Генеративно-сопоставительные сети (GAN)

6 часов

ML-3

Б/С

Содержание:

- Архитектура GAN (генератор + дискриминатор)
- Минимаксная игра, функция потерь GAN
- Проблемы обучения: затухающие градиенты (vanishing gradients), коллапс мод (mode collapse)
- DCGAN и улучшения (label smoothing, спектральная нормализация)

Практика: Запуск предобученной DCGAN, генерация изображений, обучение DCGAN с нуля, расчёт FID/KID метрик

МОДУЛЬ 4

Трансформеры и большие языковые модели (LLM)

28 часов

LLM-5, FC-2

Б/С

Содержание:

- Ограничения RNN, механизм внимания (Attention)
- Self-Attention и архитектура Трансформер (Transformer)
- Авторегрессионная генерация (GPT)
- Инженерия промптов (Prompt Engineering): Zero-Shot, Few-Shot, Chain-of-Thought
- Архитектуры современных больших языковых моделей (LLM): Llama, Mistral, Qwen
- PEFT методы: LoRA, QLoRA, Prefix Tuning
- 4-битная квантование (bitsandbytes)

Практика: Hugging Face Transformers (BERT, GPT-2), Fine-tuning BERT, LoRA/QLoRA дообучение с peft, работа с API LLM

МОДУЛЬ 5

RAG-системы и мультимодальный ИИ

18 часов

LLM-5, FC-2, PL-1, SS-1

Б/С

Содержание:

- RAG (Retrieval-Augmented Generation): архитектура и преимущества
- Векторные базы данных: Chroma, FAISS, Pinecone, Weaviate
- Эмбединги и гибридный поиск
- Оценка качества RAG (RAGAS метрики)
- Мультимодальные модели (CLIP, LLaVA, GPT-4V)
- Visual Question Answering
- Этические риски: deepfakes, bias, авторское право

Практика: Построение RAG-системы с LangChain, гибридный поиск, reranking, мультимодальные прототипы, этический аудит

МОДУЛЬ 6

AI Agents, развёртывание и диффузионные модели

26 часов

ML-3, LLM-5, PL-1

Б/С

Содержание:

- AI-агенты: концепция, отличие от чат-ботов
- Архитектура ReAct (Reason + Act)
- Типы инструментов (tools), function calling
- Мульти-агентные системы (LangGraph, AutoGen, CrewAI)
- Диффузионные модели (Stable Diffusion)
- Квантование моделей (INT8, INT4, GGUF)
- Оптимизация инференса: пакетная обработка (batching), кэширование (caching)
- Платформы: vLLM, TGI, Hugging Face Spaces

Практика: AI-агент с LangChain, мульти-агентная система, пайплайн Stable Diffusion, DreamBooth fine-tuning, FastAPI + Docker, кэширование (Redis)

ПРОМЕЖУТОЧНАЯ АТТЕСТАЦИЯ

Экзамен

- Форма:** устный экзамен (2 теоретических вопроса)
- Охват:** все модули дисциплины
- Проверяемые компетенции:** ML-2, ML-3, PL-1, LLM-5, FC-2, SS-1

Критерии оценки:

Баллы	Критерий
35-40	Полный самостоятельный верный ответ, концептуальное понимание, примеры
29-34	Достаточно полный ответ, небольшие неточности
22-28	Неполный ответ, трудности при обобщении
0-21	Разрозненные знания, ошибки в определениях

ПРАКТИЧЕСКИЕ НАВЫКИ

Инженер по машинному обучению (ML Engineer)

- Реализация MLP, автоэнкодеров, GAN с нуля
- Сравнение архитектур и оптимизаторов
- Расчёт метрик качества (FID, MSE, F1-score)

Инженер по ИИ (AI Engineer)

- LoRA/QLoRA дообучение LLM
- Построение RAG-систем с LangChain
- Развёртывание моделей (FastAPI, Docker)

Инженер по промптам (Prompt Engineer)

- Zero-Shot, Few-Shot, Chain-of-Thought промпты
- Управление параметрами генерации (temperature, top_p)
- Итеративная отладка и оптимизация промптов

Архитектор ИИ (AI Architect)

- Проектирование RAG-систем
- Архитектура AI-агентов
- Выбор моделей и оптимизация

ТЕХНОЛОГИЧЕСКИЙ СТЕК

Языки и библиотеки

- **Python** — основной язык
- **NumPy, Pandas** — работа с данными
- **PyTorch, Keras** — фреймворки глубокого обучения
- **Hugging Face Transformers** — LLM и токенизаторы
- **LangChain** — RAG и AI Agents
- **diffusers** — диффузионные модели
- **FastAPI, Docker** — развёртывание

Платформы и сервисы

- **Google Colab** — обучение и эксперименты
- **Hugging Face Hub** — модели и датасеты
- **vLLM, TGI** — инференс LLM
- **Chroma, FAISS** — векторные БД
- **Weights & Biases** — эксперименты
- **MLflow** — управление моделями

ЛИТЕРАТУРА И РЕСУРСЫ

Основная литература:

1. Vaswani A. et al. "Attention Is All You Need" (2017)
2. Touvron H. et al. "Llama 2: Open Foundation and Fine-Tuned Chat Models" (2023)
3. Hu E.J. et al. "LoRA: Low-Rank Adaptation of Large Language Models" (2022)
4. Lewis P. et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks" (2020)
5. Rombach R. et al. "High-Resolution Image Synthesis with Latent Diffusion Models" (2022)
6. Машинное обучение: учебник / Е. Ю. Бутырский и др. – Директ-Медиа, 2023

Онлайн-курсы:

- **Hugging Face Course** — <https://huggingface.co/learn>
- **DeepLearning.AI Short Courses** — <https://www.deeplearning.ai/short-courses/>
- **LangChain Documentation** — <https://docs.langchain.com/>

Журналы:

- Journal of Machine Learning Research (JMLR)
- arXiv.org (cs.LG, cs.CL, cs.CV)
- Сайт кафедры ИМС — <https://ims.sfedu.ru/>

ИТОГИ ОБУЧЕНИЯ

После завершения дисциплины студент сможет:

-  Работать с современными LLM (Llama, Mistral, Qwen)
-  Применять PEFT методы (LoRA, QLoRA) для дообучения моделей
-  Строить RAG-системы с векторными базами данных
-  Разрабатывать AI Agents с использованием инструментов
-  Развёртывать генеративные модели в production
-  Оценивать качество генеративных моделей
-  Анализировать этические риски и bias в ИИ-системах

РАБОЧАЯ ПРОГРАММА ДИСЦИПЛИНЫ

Генеративный искусственный интеллект

2026